Hugues Cassé < casse@irit.fr>

FSI - Université de Toulouse

Cours 1 : l'édition des liens



fichier source

```
int main() {
  int s = 0;
  for(int i = 0; i < 10; i++)
     s += i;
  printf("%d", s);
}</pre>
```



```
main:
    mov R0, #0
    mov R1, #0
label1:
    cmp R1, #10
    bhs label2
    add R0, R0, R1
    add R1, R1, #1
    b label1
label2:
    mov R1, R0
    adr R0, string1
    bl printf
    mov PC, LR
```

fichier source	e3a00000
	e3a01001
compilateur	e351000a
fichier assembleur	2a000002
	e0800001
assembleur	e2811001
code object	eafffffa
	e1a01000
	e28f0004
fichier exécutable	ebfffffe
	e1a0f00e

fichier source	e3a00000
	e3a01001
compilateur	e351000a
fichier assembleur	2a000002
<u> </u>	e0800001
assembleur	e2811001
code object	eafffffa
↓ ↓ ↓ · · · · · · · · · · · · · · · · ·	e1a01000
éditeur de lien	e28f0004
chier exécutable	ebffffad
nemer executable	e1a0f00e


Plan

- 1 Chargement d'un exécutable
 - L'édition des liens
- 3 Système d'exploitation avec MMU
- 4 Les systèmes embarqués
- 5 Conclusion


Un peu de vocabulaire

```
source partie de programme en langage source
objet partie de programme en langage binaire
exécutable programme complet prêt à être exécuté
bibliothèque (statique) collection de fichiers objet
bilbiothèque dynamique (ou partagée) code lié à l'exécution du
programme
image (d'un programme) configuration mémoire du
programme à son démarrage (code + données)
```

Structure physique de la mémoire



Structure logique de la RAM



Format binaire

Definition

Format des fichiers servant à stocker des programmes.

Exemples:

ELF (Exchange and Linking Format) – Unix + embarqué

PE-COFF Windows (hérité du format Unix ECOFF)

Mach-O MacOSX (plusieurs binaires d'architectures différentes)

byte-code machine virtuelle Java

Structure d'un fichier ELF

En-tête ELF:

- architecture supportant le binaire
- système supportant le binaire
- endianness (little ou big)
- taille de mot (32-bit ou 64-bit)
- adresse de démarrage

Table des sections : vue logique (éditeur de lien, débogueur, etc)
Table des en-tête de programme : chargement rapide de l'exécutable
Code + données du programme.

La commande objdump

objdump options fichier_ELF

Consultation des fichiers ELF:

- -d désassemblage des sections de code
- -f en-tête ELF
- -g information de débogage
- -h liste des sections
- -l table de correspondance ligne-source / adresse
- -r liste des relocationss
- -t liste des symboles définis et utilisés

Alternative : readelf (plus orientée ELF)

En-tête programme

en-tête programme = segment de mémoire dans l'image du programme

Caractéristiques :

- adresse dans l'image
- position dans le fichier
- taille (en octet)
- droits d'accès (exécution, lecture, écriture)

fonction \implies lecture + exécution (mémoire du code) variables globales \implies lecture + écriture (mémoire statique) données constantes \implies lecture

Chargement d'un programme

Le chargeur de programme :

- 1. lit les en-têtes programme du fichier exécutable
- 2. copie des segments de programme initialisés à leur adresse
- 3. met à 0 des données globales non-initialisées
- 4. initialise la pile et le pointeur SP
- 5. lance le programme (PC ← adresse de démarrage).

Le chargeur peut être :

- le système d'exploitation
- un installeur de logiciel sur une plate-forme embarquée (JTAG, ...)
- un simulateur de microprocesseur (QEmu)

Plan

- 1 Chargement d'un exécutable
- 2 L'édition des liens
- Système d'exploitation avec MMU
- 4 Les systèmes embarqués
- 5 Conclusion

Objectif file1.o file2.o Exécutable Éditeur de lien filen.o lib1.a libm.a

Les sections

Caractéristiques :

- adresse dans l'image
- position dans le fichier
- taille, alignement en mémoire
- droits d'accès

Sections classiques :

- .text code
- .data variables globales initialisées
- .rodata constantes
 - .bss variables globales non-initialisées
- .debug_line table de correspondance ligne/source \Leftrightarrow adresse .debug_XXX information sur les entités du programme

Problème de l'édition des liens

```
file.h
void f();
                        file.o
extern int x;
                        f:
file.c
                                                  main.elf
void f {
                        x: .int 1;
                                                  f:
int x = 1:
                                                  x: .int 1;
                        main.o
main.c
#include
                                                  main:
                        main:
"file.h"
void main() {
                           . . .
                                                    BI. 0x1028
                          BL ? (@f)
  f();
                                                    ADR R3, 0x301C
                          ADR R3, ? (@x)
  x = \ldots;
```

Sections d'édition de lien

. symtab (bibliothèque) – liste des symboles exportés

- nom du symbole
- section contenant le symbole
- position dans la section
- taille du symbole
- nature du symbole (étiquette, fonction, donnée constante)

.rel.XXX ou .rela.XXX (exécutable) - opération de relocation

- XXX = section relogée
- symbole adressé
- position dans la section
- calcul de la relocation (dépendant de l'architecture)

Processus d'édition des liens

- construction de l'ensemble des objets nécessaires (programme + objets nécessaires des bibliothèques)
- 2. agrégation des sections de même type
- 3. détermination des adresses des sections
- 4. relocation des sections

Construction de l'ensemble des objets

```
let \ Libs = \{ set \ of \ libraries \}
let Objs = {objets du programme}
let Imps = \bigcup_{obi \in Obis} imports(obj)
let Exps = \bigcup_{obj \in Objs} exports(obj)
while Imps \neq \emptyset do
    let s \in Imps
    Imps \leftarrow Imps \setminus \{s\}
    if s \notin Exps then
       if \exists obj \in Libs \land s \in exports(obj) then
            Objs \leftarrow Objs \cup \{obj\}
            Exps \leftarrow Exps \cup exports(obj)
            Imps \leftarrow Imps \cup imports(obj)
       else
            error "symbole manquant"
       end if
    end if
end while
```

file.o

- imports = {printf}
- $exports = \{f, x\}$

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- *exports* = {_start}

- *imports* = {...}
- exports = {..., printf, ...}

```
1. Objs =
    {crt0.o,main.o,file.o}
    Imps = {main,f,x,printf}
    Exps = {main,f,x,_start}
```

file.o

- imports = {printf}
- exports = {f, x}

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- *exports* = {_start}

- *imports* = {...}
- exports = {..., printf, ...}

- 1. Objs =
 {crt0.o,main.o,file.o}
 Imps = {main,f,x,printf}
 Exps = {main,f,x,_start}
- 2. main ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {f,x,printf}
 Exps = {main,f,x,_start}

file.o

- imports = {printf}
- exports = {f, x}

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- exports = {_start}

- *imports* = {...}
- exports = {..., printf, ...}

- 1. Objs =
 {crt0.o,main.o,file.o}
 Imps = {main,f,x,printf}
 Exps = {main,f,x,_start}
- 2. main ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {f,x,printf}
 Exps = {main,f,x,_start}
- 3. f ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {x,printf}
 Exps = {main,f,x,_start}

file.o

- imports = {printf}
- exports = {f, x}

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- exports = {_start}

- *imports* = {...}
- exports = {..., printf, ...}

- 1. Objs =
 {crt0.o,main.o,file.o}
 Imps = {main,f,x,printf}
 Exps = {main,f,x,_start}
- 2. main ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {f,x,printf}
 Exps = {main,f,x,_start}
- 3. f ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {x,printf}
 Exps = {main,f,x,_start}
- 4. x ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {printf}
 Exps = {main,f,x,_start}

file.o

- imports = {printf}
- $exports = \{f, x\}$

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- exports = {_start}

libc.a / printf.o

- *imports* = {...}
- exports = {..., printf, ...}

4. x ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {printf}
 Exps = {main,f,x,_start}

file.o

- imports = {printf}
- $exports = \{f, x\}$

main.o

- $imports = \{f, x\}$
- exports = {main}

crt0.o

- imports = {main}
- exports = {_start}

libc.a / printf.o

- *imports* = {...}
- exports = {..., printf, ...}

4. x ∈ Exps
 Objs =
 {crt0.o,main.o,file.o}
 Imps = {printf}
 Exps = {main,f,x,_start}

5. printf \notin Exps \improx
 printf.o added
 Objs =
 {crt0.o,main.o,file.o,printf.o}
 Imps = {}
 Exps =
 {main,f,x,_start,printf}

Le script d'édition des liens

Comportement par défaut :

- architecture, système, endianness fichiers objets (identique pour tous)
- adresse de démarrage = _start
- section = concaténation des sections des objets liés
- affectation d'une adresse à chaque section (en suivant les contraintes d'alignement)
- relocation en utilisant les sections .rel.XXX et .rela.XXX (qui disparaissent)

Exemple

Objet	.text	.data	.bss
crt0.o	540	a0	120
main.o	f00	b00	1800
file.o	a00	100	100
printf.o	400	100	a0

Tailles en hexadécimal et en octet.

Contraintes d'alignement : 4 KO (0x1000) pour chaque section.

	Adresse	section
	0000 0000	crt0.o (.text)
	0000 0540	main.o(.text)
	0000 1440	file.o(.text)
	0000 1e40	<pre>printf.o (.text)</pre>
	0000 2240	fin de section .text
	0000 3000	crt0.o (.data)
	0000 30a0	main.o (.data)
	0000 3ba0	file.o (.data)
ĺ	0000 3ca0	<pre>printf.o (.data)</pre>
ĺ	0000 3cb0	fin de section .data
ĺ	0000 4000	crt0.o(.bss)
	0000 4120	main.o(.bss)
	0000 5920	file.o(.bss)
ĺ	0000 5a20	printf.o(.bss)
ĺ	0000 5ac0	fin de section .bss
	0000 5ac0	(mémoire dynamique)

Utilisation d'un script

Édition de lien spécialisée :

```
SECTIONS {
   .text : { *(.text) }
   .data : { *(.data) }
   .bss : { *(.bss) }
}
```

Syntaxe:

- script → SECTIONS {section*}
- section → name: {contenu*}
- $contenu \rightarrow ER_{fichier}(section^*)$

Exercice 1

Objet	.text	.data	.bss
crt0.o	200	20	f0
main.o	b00	400	1000
file1.o	200	500	2000
file2.o	200	500	a000

Calculez l'adresse des sections pour le script ci-dessous.

```
SECTIONS {
   .text : { *(.text) }
   .data : { *(.data .bss) }
}
```

Au niveau compilateur

- ⇒ remplir les sections
 - fonctions ⇒ .text
 - données constantes / chaînes de caractère ⇒ .rodata
 - variables locales initialisées ⇒ .data
 - variables locales non-initialisées \Rightarrow .bss
- ⇒ génération de la table des symboles (.symtab) :
 - identificateur fonction / variable
 - section
 - déplacement
- ⇒ variables locales (pile)
 - taille de bloc d'activation
 - déplacement dans le bloc (locale)
 - déplacement avant le bloc (paramètres)

Exercice 2

Nous voulons écrire un script pour lier des fichiers .o composés des sections .text, .rodata, .data et .bss.

- Écrire le script pour que chacune des sections soient liées dans une section de l'exécutable correspondant : les .text dans .text. etc.
- Modifiez le script pour que .text et .rodata soient dans la même section .text (l'un juste après l'autre).
- Modifiez le script pour créer une section .start contenant le .text et le .rodata des fichiers .o préfixés par start.

Assembleur et édition des liens

```
Choisir une section:
      .text - constant + exécutable
      .data - variable
     .lcomm nom, longueur - dans la .bss
  .section nom[, "options"]
Travailler avec les symboles :
    .global noms – symboles visibles à l'extérieur
    .extern noms – symboles définis dans un autre fichier
      .size nom, taille – définition de taille de symbole
```

Autres commandes :

```
.align alignement
.file fichier, ligne
```

Compilateur et édition des liens

```
extern, static — propriétés de symbole

Attributes de GCC : __attribute__ (attribut)

aligned (alignement)

section ("name")

weak — accepte des doublons
```

Commandes

Compilation et édition des liens :

```
cc -o excutable objets -1lib_1 -1lib_2 ...
```

Bibliothèque statique = collection d'objets

- Unix libXXX.a ar rcs libXXX.a objets
- Windows XXX.lib
 lib -out: XXX.lib objets

Options de gcc

-T script – script d'édition ds liens

-Xlinker option – passage d'option à l'éditeur de lien

L'éditeur de lien 1d

Options:

- -e nom − symbole de démarrage
- -1 bibliotheque
- -L chemin pour retrouver les bibliothèques
- -T script
- -T section=adresse fixe l'adresse d'une section
 (.text, data ou .bss)

Plan

- Chargement d'un exécutable
- 2 L'édition des liens
- 3 Système d'exploitation avec MMU
- 4 Les systèmes embarqués
- 5 Conclusion

La MMU

Isolation:


- 1 processus = 1 espace d'adressage virtuel
- protection des erreurs des autres processus

Mémoire virtuelle :

- moins de contrainte pour le programme
- stockage sur le disque dur


Mémoire physique :

0 physique $\neq 0$ virtuelle



La MMU

MMU = Memory Management Unit



MMU et système d'exploitation

Interruptions lors de l'accès à une page :

- page non-exécutable ⇒ arrêt
- page non-modifiable
 - résultat d'un fork ⇒ duplication (Unix)
 - sinon arrêt
- page indisponible
 - zone privée ⇒ arrêt
 - mémoire dynamique \Rightarrow allocation réelle d'une page physique
 - page sauvegardée sur le disque ⇒ allocation page physique + rechargement ⇒ déchargement d'une autre page
 - page correspondant à un fichier ⇒ allocation page physique + chargement ⇒ déchargement d'une autre page

Processus de chargement avec MMU


Le système d'exploitation :

- 1. crée un descripteur de processus contenant la correspondance entre pages virtuelles/physiques
- 2. alloue des pages pour stocker les segments
- 3. charge les segments du disque dans les pages mémoire
- 4. met à 0 les données non-initialisées
- 5. alloue des pages mémoire pour stocker la pile
- 6. initialise SP et la pile avec des informations systèmes (arguments de commande)
- 7. lance le programme à l'adresse de démarrage


Principe

- édition des liens au chargement du programme
- déjà en mémoire \implies partage des pages \implies réduction de la place mémoire
- pas en mémoire ⇒ recherche et chargement /lib, usr/lib ou dans \$LD_LIBRARY_PATH
- exécutable
 - dynamic information pour l'édition des liens
 - édition des liens avec -1XXX
- bibliothèque partagée (libXXX.so)
 - compilée avec -shared
 - compilée avec -fPIC (Position Independent Code)
 - symboles dans .symtab

Partage des pages



Relocation dynamique



PLT = Procedure Linkage Table GOT = Global Offset Table

Programmer la MMU

```
Bibliothèque standard :
```

```
mmap - allocation de page
munmap - désallocation de page
Bibliothèque dl (dynamic linkage) :
    dlopen (chemin, options)
    dlclose (handle)
    dlsym (handle, nom)
    dlinfo (handle, ID, pointer)
```

Options de dlopen :

```
LAZY édition de lien paresseuse
NOW édition de lien immédiate
GLOBAL symboles de la biblothèque publics
LOCAL symboles de la bibliothèque privés
```

Commandes Unix

- Compilation d'une bibliothèque dynamique :
 cc -shared -o libXXX.so objets
- Objets compilés avec -fpic ⇒ relocation dynamique
- ld.config chargement de programme et édition des liens dynamique (Unix)
- ldd [-r -d] executable vérification d'édition des liens
- objdump -T executable liste des symboles dynamiques
- readelf -d executable information d'édition des liens dynamiques

Bilan

- nécessaire pour économiser de la mémoire
- coût
 - code un peu moins efficace
 - table .plt et .got
 - édition de lien à l'exécution
 - ⇒ liaison paresseuse
- autres gains
 - taille des fichiers exécutables
 - mise à jour des bibliothèques indépendantes
 - mise en œuvre de greffon bibliothèque d1 : dlopen(), dlsym()

Plan

- Chargement d'un exécutable
- L'édition des liens
- 3 Système d'exploitation avec MMU
- 4 Les systèmes embarqués
- 5 Conclusion

Caractéristiques

Espace d'adressage non-uniforme :

- RAM (Random Access Memory) modifiable, perdu au redémarrage
 - \implies variables globales + tas + pile
- ROM (Read-Only Memory) difficilement modifiable mais survit à un redémarrage (FLASH)
 - ⇒ code + données read-only
- IO (Intput / Output) registres réservés pour les entrées / sorties
- ⇒ très différent d'une machine à l'autre

NOTE: s'applique également au noyau d'un système d'exploitation

Description de la mémoire dans un script

```
MEMORY {
  ROM (RIX): ORIGIN = 0, LENGTH = 3M
  RAM (RW): ORIGIN = 0x10000000, LENGTH = 1M
}
```

Mémoire définie par :

- nom
- ORIGIN adresse de base
- LENGTH taille
- attributes (R, W, X, A, I)

Script avec désignation de la mémoire

```
SECTIONS {
   .text : { *(.text) } > ROM
   .data : { *(.data) } > RAM
   .bss : { *(.bss) } > RAM
}
```

Problème : au démarrage, la RAM est vide ⇒ .data n'est pas initialisée.

- 1. installer la .data dans la ROM (éditeur de lien)
- 2. copie la .data de la ROM dans la RAM (application embarquée)

Concept:

VMA (Virtual Memory Address) adresse virtuelle (adresse logique en fonctionnement)

LMA (Load Memory Address) adresse de chargement

Chargement de .data en ROM

```
SECTIONS {
  .text.start : {
    startup.o(.text )
  } > R.OM
  .text : {
   *(.text)
    _{\text{TEXT}}_{\text{END}} = .;
  } > ROM
  .data : {
    _DATA_START_ = .;
    *(.data)
    _DATA\_END\_ = .;
  } > RAM AT(_TEXT_END_)
```

Manipulation des adresses

- nom = addr; définition d'une adresse nommée (+=, -=, etc)
- . adresse courante
- constante décimal, 0x hexadécimal, suffixé par K, M, etc
- nom référence à une autre adresse
- $addr_1$ op $addr_2$ avec $op \in \{+, -, *, /, \%, <<, >>, ...\}$
- ADDR(section) adresse VMA d'une section
- LOADADDR(section) adresse LMA d'une section
- SIZEOF(section) taille d'une section
- ALIGN(alignement) adresse courante alignée
- NEXT(alignement) adresse suivante alignée et non-allouée

Les définitions d'adresse peuvent être réalisées n'importe où dans la définition de section!

Construire l'image au démarrage

Problème : les variables globales ne sont pas initialisées ! **Solution** :

- copier .data de la ROM à la RAM au démarrage
- adresse de début dans la RAM _ DATA_START_
- adresse de début dans la ROM _TEXT_END_

```
extern char _DATA_START_ , _DATA_END_;

void init() {
   memcpy(
        &_DATA_START_ ,
        &_TEXT_END_ ,
        &_DATA_END_ - &_DATA_START_);
}
```

Exercice 3

- 1. Modifiez le script initial pour prendre en compte les sections .bss.
- 2. Ecrivez le code qui permet de mettre à 0 le code de la section .bss.

Exercice 4

Dans certains contextes de fonctionnement (spatial, avionique), un programme peut être altéré par des perturbations extérieures (SEU – Single Event Upset et il est dangereux de laisser un tel programme fonctionner. Pour détecter les erreurs, on réalise une somme de contrôle (la somme des mots composant le programme) et re-calculons cette somme régulièrement. Si la somme change, le programme est altéré et on l'arrête proprement.

- 1. un script d'édition des liens
- 2. la fonction de calcul de somme de contrôle, compute_sum() pour prendre en compte ce problème.

Générer du contenu

```
Dans le contenu d'une section :
```

```
BYTE (entier8 - bit)

SHORT (entier16 - bit)

LONG (entier32 - bit)

QUAD (entier64 - bit)

FILL (octets) – remplissage des parties non-spécifiées
```

Exemple 1 : vecteurs d'initialisation

```
Table de vecteurs d'initialisation :
                                          Exploitation du tableau :
SECTIONS {
  .init : {
     init_size = .;
     LONG (
        (_INIT_END_ - _INIT_BEGIN_)/4);
     init_tab = .;
                                          Ou alors:
     _{\rm INIT\_BEGIN\_} = .;
     *(.init)
     _{\rm INIT\_END\_} = .;
     LONG(0)
```

Exemple 1 : vecteurs d'initialisation

```
Table de vecteurs d'initialisation :
                                      Exploitation du tableau :
SECTIONS {
                                      typdef void (*init_t)();
  .init : {
                                      extern int init__size;
                                      extern init t init tab):
    init_size = .;
    LONG (
                                      for(i = 0; i < init_size;</pre>
       ( INIT END - INIT BEGIN )/41++)
                                         init_tab[i]();
    init_tab = .;
                                      Ou alors:
    INIT BEGIN = .:
    *(.init)
    _{\rm INIT\_END\_} = .;
    LONG(0)
```

Exemple 1 : vecteurs d'initialisation

```
Table de vecteurs d'initialisation :
                                      Exploitation du tableau :
SECTIONS {
                                      typdef void (*init_t)();
  .init : {
                                      extern int init__size;
                                      extern init t init tab):
    init_size = .;
    LONG (
                                      for(i = 0; i < init_size;</pre>
       ( INIT END - INIT BEGIN )/41++)
                                        init_tab[i]();
    init_tab = .;
                                      Ou alors:
    INIT BEGIN = .:
    *(.init)
                                      for(i = 0; init_tab[i] != NULL;
    _{\rm INIT\_END\_} = .;
                                      i++)
    LONG(0)
                                        init_tab[i]();
```

Exemple 2 : objets globaux en C++

```
class MyClass {
  MyClass(int x)
MyClass glob(1024);
section .ctor:
  adr RO, glob
  mov R1, #1024
  bl MyClass_MyClass_int
section .dtor:
  adr RO, glob
     MyClass_~MyClass_int
  bl
```

Exemple 2 : objets globaux en C++

```
class MyClass {
  MyClass(int x)
MyClass glob(1024);
section .ctor:
  adr RO, glob
  mov R1, #1024
  bl MyClass_MyClass_int
section .dtor:
  adr RO, glob
  bl MyClass_~MyClass_int
```

En C++, code de construction et de destruction des objets globaux : SECTIONS {

Exercice 5

Nous voulons réaliser un système embarqué composé de modules. Selon les cibles du système embarqués, certains modules seront utilisés et d'autres pas. Chaque module est identifié par la structure de donnée, ci-dessous, contenue dans les sources du module :

```
typedef struct module_t {
  const char *name;
  uint32_t version;
  void (*init)();
  void (*fini)();
} module_t;
```

Afin de gérer les modules de manière flexible, on va utiliser l'éditeur de lien pour générer une table des modules se terminant par une structure dont l'adresse du nom est 0. Indiquez :

- 1. comment déclarer les modules dans les sources,
- 2. le script d'édition de lien,
- 3. la fonction d'initialisation des modules.

Plan

- 1 Chargement d'un exécutable
- 2 L'édition des liens
- 3 Système d'exploitation avec MMU
- 4 Les systèmes embarqués
- 5 Conclusion

Conclusion

L'édition des liens :

- assemble les objets constituant un programme
- construit l'image mémoire du programme
- libère le compilateur de ces questions

La tâche du compilateur devient :

- la génération du code et des données
- le remplissage des sections correspondant aux objets compilés